Αναφορά: Πρόβλεψη Alzheimer's με Χρήση Νευρωνικών Δικτύων

Νίκος Ανδριανόπουλος
Α.Μ. φοιτητή: 1084637
up1084637@ac.upatras.gr

12 Απριλίου 2025

Περιεχόμενα

1 Εισαγωγή

Στην παρούσα εργασία μελετάω τη χρήση Τεχνητών Νευρωνικών Δικτύων (ΤΝΔ) για την πρόβλεψη της νόσου Alzheimer, χρησιμοποιώντας το σύνολο δεδομένων που παρέχεται (Alzheimer's Disease Dataset). Στόχος είναι να ταξινομήσουμε ασθενείς σε δύο κλάσεις (Alzheimer ή μη) βάσει διαφόρων χαρακτηριστικών (βιοδείκτες, συμπτώματα, κ.λπ.).

Παρακάτω παρουσιάζονται τα βήματα που ακολουθήθηκαν, σύμφωνα με τα ερωτήματα του Μέρους Α' της εργασίας.Τα αποτελέσματα είναι κομμάτια των json αρχείων που δημιουργούνται μετά την εκτέλεση του κώδικα, βάζω την χρήσιμη πληροφορία για την απάντηση του κάθε ερωτήματος όχι όλο το json. Οι τιμές μπορεί να είναι λιγο διαφορετικές, επειδή χρησιμοποιείται η gpu από ερώτημα σε ερώτημα αλλά οι διαφορές μεταξύ των τιμών είναι πάντα σταθερές(π.χ.η=0.001 δίνει καλύτερη απόδοση απο η=0.05).

2 Α1: Προεπεξεργασία και Προετοιμασία Δεδομένων

2.1 (α) Κωδικοποίηση και προεπεξεργασία δεδομένων

Στο σύνολο δεδομένων εντοπίστηκαν κατηγορικές και ποσοτικές μεταβλητές, οπότε:

- **One-hot encoding:** Εφαρμόστηκε στις κατηγορικές στήλες:*Ethnicity*, *Education Level*, οι οποίες έχουν τιμές στο [0,3].Πρέπει να γίνει αυτή η αλλαγή καθώς το 0 από το 3 στη συγκεκριμένη περίπτωση δεν έχει κάποια επιπλέον πληροφορία αλλά αν το αθροίσουμε επειδή είναι μεγαλύτερος αριθμός θα δώσει.
- **Κανονικοποίησής/Τυποποίηση:** (Π.χ.) Χρησιμοποιήθηκε η *z-score* μέθοδος για να παρέχω στις στήλες με συνεχείς τιμές στατιστικές ιδιότητες.
- Για τις στήλες που έχουν δυαδικές τιμές δεν κάνω κάποια αλλαγή γιατί δεν υπάρχει κίνδυνος υπερεκτίμησης της πληροφορίας.

Στις συνεχείς στήλες βέβαια μπορώ να κάνω centering και min-max, αλλά η τυποποίηση είναι καλύτερη και από τις 2 μεθόδους γιατί κεντράρει αλλά και κλιμακώνει ταυτόχρονα τα δεδομένα, όλα τα χαρακτηριστικά συνεισφέρουν ομοιόμορφα στη μάθηση.Στην πράξη:


```
{
    "pre_processing":"centering"
    "Average loss": 0.5412922739982605,
    "Average Accuracy": 0.7603491067886352,
    "Average MSE": 0.16807735860347747
}

{
    "pre_processing":"min-max"
    "Average loss": 0.3923275530338287,
    "Average Accuracy": 0.8306109428405761,
    "Average MSE": 0.1211971566081047
}

{
    "pre_processing":"z-score"
    "Average loss": 0.39323789477348325,
    "Average Accuracy": 0.8394557356834411,
    "Average MSE": 0.12149734944105148
}
```

Κώδικας του pre-processing:

```
    def min_max(panda,columns):
        scaler = MinMaxScaler(feature_range=(-1, 1))
        normalized_data = scaler.fit_transform(panda[columns])

        return normalized_data

    def centering(panda,columns):
        scaler = StandardScaler(with_std=False)
        centered_data = scaler.fit_transform(panda[columns])

        return centered_data

    def z_score(panda,columns):
        scaler = StandardScaler()
        cont_val=panda[columns]
        zscored_data = scaler.fit_transform(panda[columns])

        return zscored_data
```

Τέλος κάνω concatenate τα δεδομένα μώλις γίνουν numpy arrays και τα κάνω cast όλα σε float32, επειδή βοηθάει τις gpu στις πράξεις.

```
filtered_input=np.concatenate([pre_processed_input, \
encoded_input,binary_input], axis=1).astype(np.float32)
```

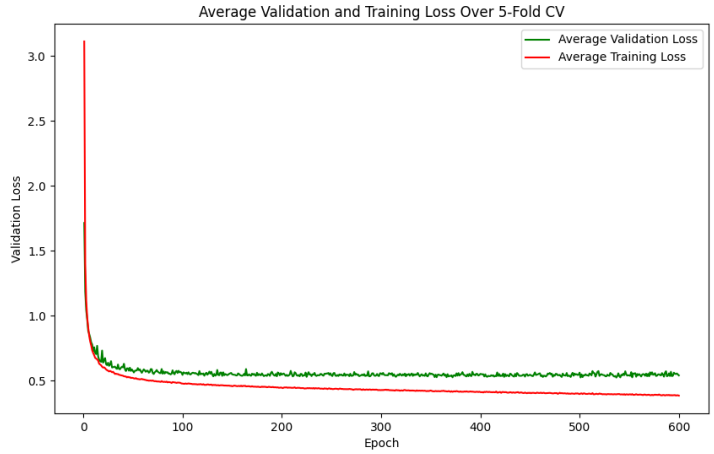

(α□) Centering

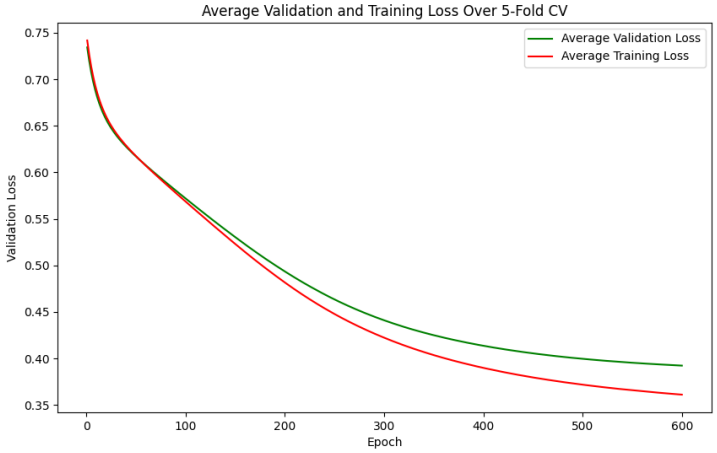

(β□) Min-max

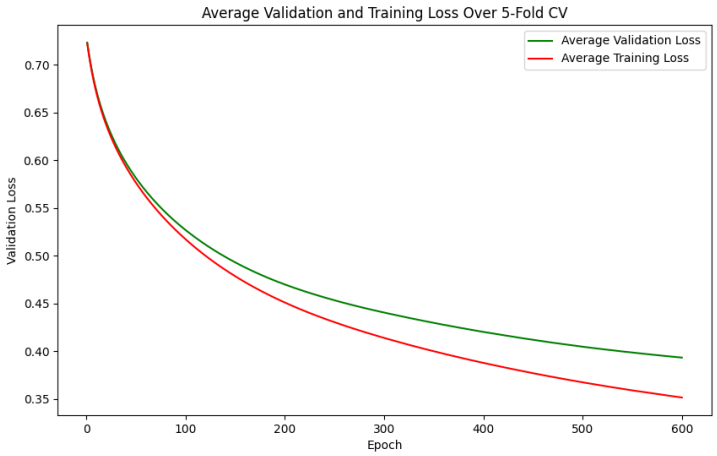

(γ□) z-score

Σχήμα 1: Όπως φαίνεται από τις γραφικές παραστάσεις και τα αποτελέσματα το z-score έχει καλύτερη απόδοση, μικρό loss και πιο ομαλές γραφικές παραστάσεις.

2.2 (β) Διασταυρούμενη Επικύρωση (5-fold CV)

Για την αξιόπιστη εκτίμηση των επιδόσεων των μοντέλων, χρησιμοποιήθηκε *5-fold Cross Validation*.Τα folds να είναι *ισορροπημένα* ως προς τον αριθμό δειγμάτων ανά κλάση. Σε κάθε πείραμα:

- Διαχωρίστηκαν τα δεδομένα σε 5 $\approx$ ίσα τμήματα (folds).
- Κάθε φορά, 4 folds χρησιμοποιήθηκαν για εκπαίδευση και 1 για έλεγχο.
- Επαναλήφθηκε η διαδικασία 5 φορές και υπολογίστηκε ο μέσος όρος των μετρικών.

Κώδικας του pre-processing:

```
def normal_training(filtered_input,output,args,folder,hidden_layers):
        five_fold = StratifiedKFold(n_splits=5, shuffle=True, random_state=44)
        round=1
        evals=[]
        val_loss_table=[]
        loss_table=[]
        early_stop_epochs=[]
        batch_size=32

        for training_idx,val_idx in five_fold.split(filtered_input,output):

            input_train,input_val=filtered_input[training_idx],filtered_input[val_idx]
            output_train,output_val=output[training_idx],output[val_idx]


            model,early_stop=nn_model(parameters)
            training=model.fit(input_train, output_train,
            validation_data=(input_val, output_val),epochs=args.epochs, batch_size=batch_size)

            stop_epoch=len(training.history['loss'])
            early_stop_epochs.append(stop_epoch)

            val_loss_table.append(training.history['val_loss'])
            loss_table.append(training.history['loss'])
```

```
    parameters:
    filtered_input.shape[1],
    args.optimizer,
    args.momentum,
    args.lr,
    args.num_of_layers,
    args.hid_layer_func,
    args.loss_func,
    args.use_l2,
    args.use_l1,
    args.r,
    args.more_layers,
    hidden_layers
```

Οι παραμέτροι κυρίως είναι για τα επόμενα ερωτήματα και εξηγούνται πλήρως στον parser του κώδικα στο github, ορισμένοι θα εξηγηθούν στα επόμενα ερωτήματα.

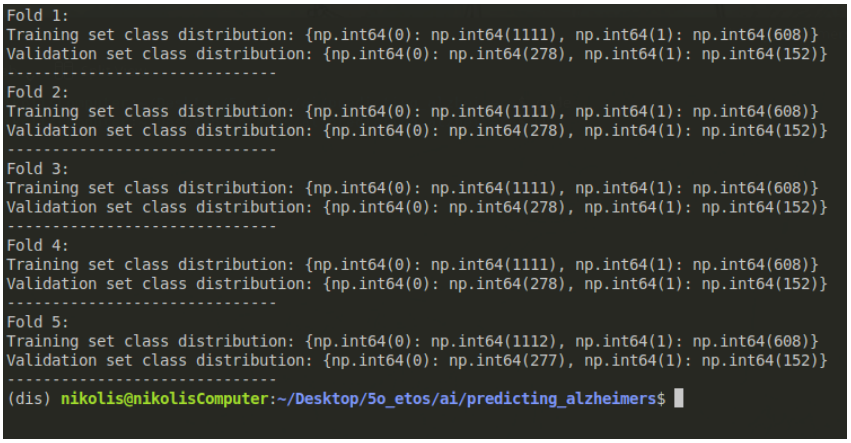

Σχήμα 2: Το split έχει γίνει σωστά και ισορροπημένα

3 Α2: Επιλογή Αρχιτεκτονικής

3.1 (α) Σημασία των μετρικών CE, MSE, Accuracy

- **Cross-Entropy (CE) loss:** Καταλληλότερη σε περιπτώσεις ταξινόμησης, καθώς τιμωρεί έντονα σφάλματα στην πιθανότητα της σωστής κλάσης και συνήθως οδηγεί σε καλύτερη σύγκλιση.
- **Μέσο Τετραγωνικό Σφάλμα (MSE):** Χρησιμοποιείται συχνά σε προβλήματα παλινδρόμησης. Σε ταξινόμηση μπορεί να οδηγήσει σε βραδύτερη/όχι ιδανική σύγκλιση.Εδώ χρησιμοποιείται μόνο σαν μέτρο της απόστασης των προβλέψεων από τις validation τιμές, για τη σύγκριση των διαφόρων πειραμάτων.
- **Ακρίβεια (Accuracy):** Αφορά το ποσοστό σωστών προβλέψεων. Δεν είναι συνήθως η βέλτιστη *συνάρτηση κόστους* για εκπαίδευση.Τη χρησιμοποιώ πάλι για τη σύγκριση των πειραμάτων.

Συμπέρασμα: Για την εκπαίδευση (loss) χρησιμοποιώ CE, ενώ για αναφορά τελικών επιδόσεων χρησιμοποιώ ακρίβεια.Προεραιτικά χρησιμοποιώ και MSE μαζί με την ακρίβεια για τη σύγκριση των επιδόσεων.

3.2 (β) Αριθμός νευρώνων στο επίπεδο εξόδου

Για μια *binary classification* (Alzheimer ή μη) αρκεί:

- 1 νευρώνας εξόδου με σιγμοειδή λειτουργία (παραγωγή $x \in (0, 1)$), ή
- 2 νευρώνες εξόδου με *Softmax*, με one hot encoding (πιο γενικευμένη προσέγγιση).

Και τα 2 βγάζουν ίδια αποτελέσματα, οποτέ υλοποιώ το πιο απλό(Sigmoid):


```
{
    "softax":"yes",
    "Average loss": 0.39862353801727296,
    "Average Accuracy": 0.8397802214622497,
    "Average MSE": 0.12448595911264419

    ========================================
```

```
"sigmoid":"yes",
"Average loss":0.39606810808181764
"Average Accuracy":0.83433837890625
"Average MSE":0.1230233833193779

}
```


3.3 (γ) Επιλογή συνάρτησης ενεργοποίησης στους κρυφούς κόμβους

- **Tanh:** Καλύτερη κλίμακα τιμών από τη σιγμοειδή (παράγει τιμές σε $[-1, 1]$), αλλά μπορεί να υποφέρει από vanishing gradients.
- **ReLU:** Συχνά προτιμάται σε βαθιά δίκτυα, έχει γρήγορη σύγκλιση, αλλά υπάρχει η περίπτωση "dying ReLUs".
- **SiLU:** Εναλλακτική που σε ορισμένες περιπτώσεις ξεπερνά σε επίδοση το ReLU, αλλά είναι πιο σύνθετη.

Πάλι όλες βγάζουν παρόμοια αποτελέσματα οπότε επιλέγω την πιο απλή και πιο ευρέως προτιμημένη:


```
{
    "hidden layer activation function":"Tanh",
    "Average loss": 0.39862353801727296,
    "Average Accuracy": 0.8334038019180298,
    "Average MSE": 0.11632926613092423

    ========================================

    "hidden layer activation function":"Silu",
    "Average loss":0.39606810808181764
    "Average Accuracy":0.83433837890625
    "Average MSE":0.1230233833193779

    ========================================

    "hidden layer activation function":"Relu"
    "Average loss": 0.39323789477348325,
    "Average Accuracy": 0.8394557356834411,
    "Average MSE": 0.12149734944105148

}
```


3.4 (δ) Συνάρτηση ενεργοποίησης στο επίπεδο εξόδου

- Εξηγήθηκε πριν, έχει επιλεχτεί η Sigmoid.

3.5 (ε) Αριθμός νευρώνων στο κρυφό επίπεδο και αποτελέσματα

I=38 είναι ο αριθμός εισόδων. Ακολουθούν τιμές και γραφήματα σύγκλισης:

Νευρώνες H	**CE Loss**	**MSE**	**Accuracy**
$I/2$	0.3937569260597229	0.12326516360044479	0.8310836553573608
$2I/3$	0.3960006356239319	0.12397604882717132	0.8320052027702332
I	0.3982479512691498	0.12300745993852616	0.8310847401618957
$2I$	0.3929096460342407	0.12164172381162644	0.8329386830329895

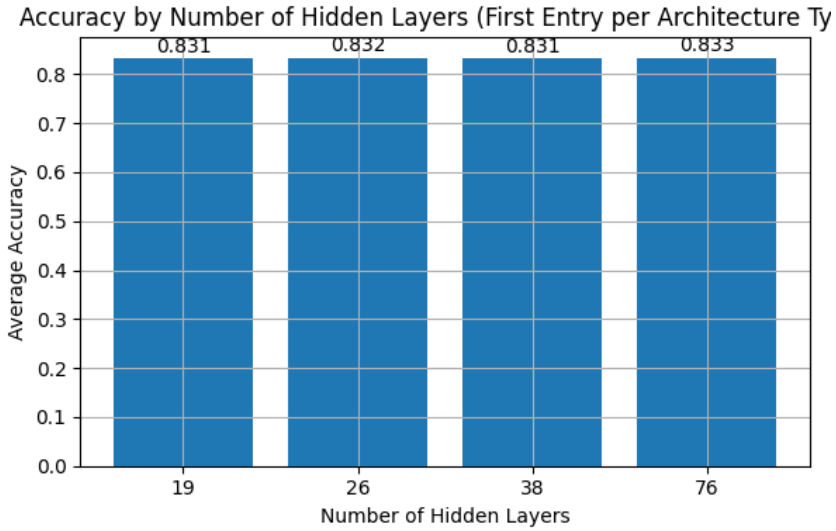

Σχήμα 3: Οι τιμές σε γράφημα

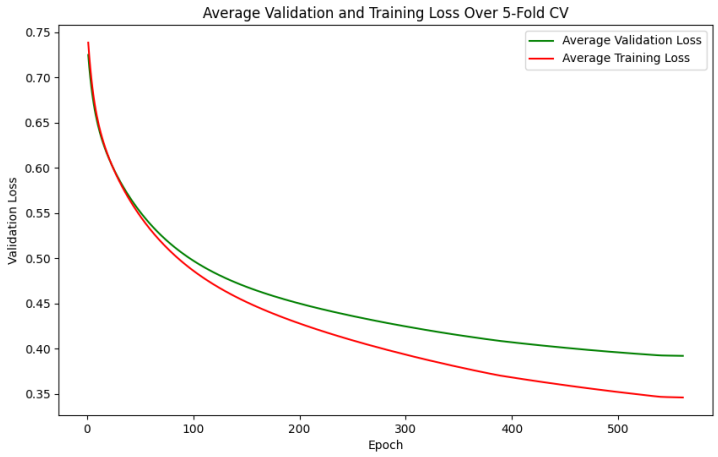

Σχήμα 4: 2*I

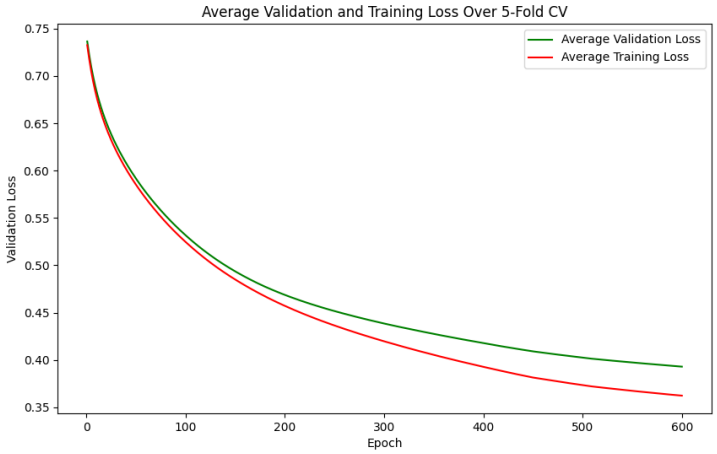

Σχήμα 5: I/2

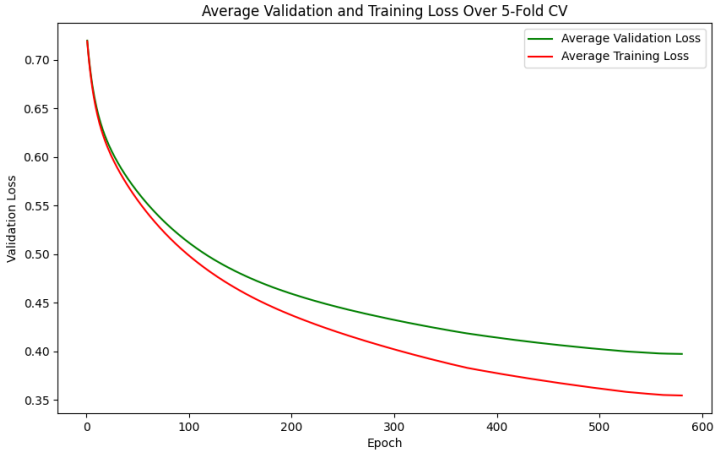

Σχήμα 6: I

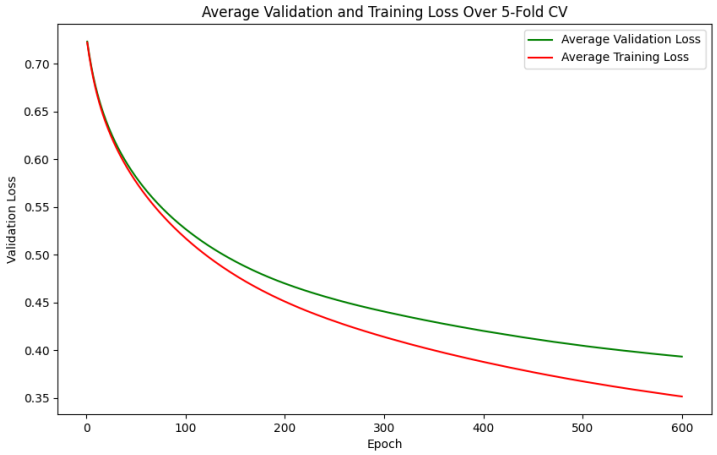

Σχήμα 7: 2*I/3

Συμπεράσματα:

- *(i)* Κατάλληλος αριθμός κρυφών νευρώνων: 2*I, Όπως φαίνεται και από πάνω τα καλύτερα αποτελέσματα τα δίνει ο μεγαλύτερος αριθμός νευρώνων. Επιπλέον, εκτός από το καλύτερο accuracy έχει το την πιο χαμηλή και ομαλή συνάρτηση validation loss:

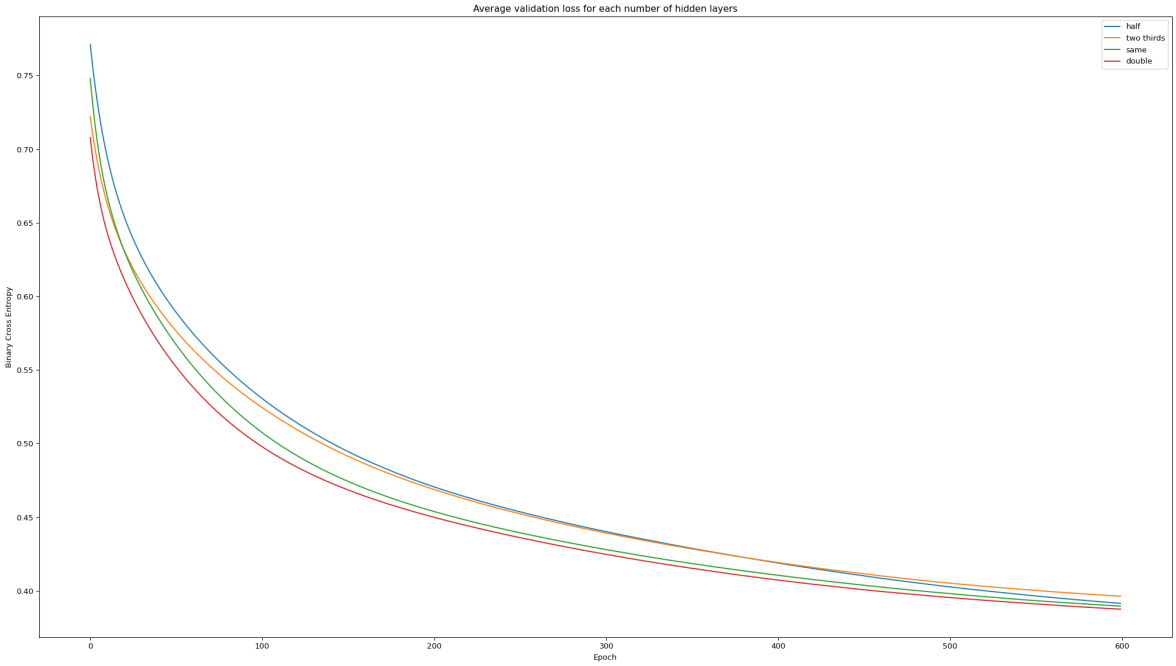

Σχήμα 8: Validation-loss plot για τα διαφορετικά νούμερα νευρώνων

- *(ii)* Συνάρτηση κόστους που δίνει βέλτιστη απόδοση: Binary-Crossentropy, το πρόβλημα είναι δυαδική ταξινόμηση οπότε, η συνάρτηση που μετράει πόσο διαφέρει η πρόβλεψη από την πραγματική τιμή για ένα δυαδικό αποτέλεσμα είναι η φυσική επιλογή.

- *(iii)* Συνάρτηση ενεργοποίησης που οδηγεί σε βέλτιστη μάθηση: Relu όπως εξηγήθηκε.

- *(iv)* Ταχύτητα σύγκλισης / εποχές εκπαίδευσης: Για να βρώ τα κατάλληλα epochs που αρχίζει να υπερεκπεδεύται το δείγμα, αρκεί να κάνω το plot Training-Validation loss και να δω από ποιο epoch αρχίζει το validation-loss να παραμένει σταθερό ενώ το training συνεχίζει να μειώνεται:

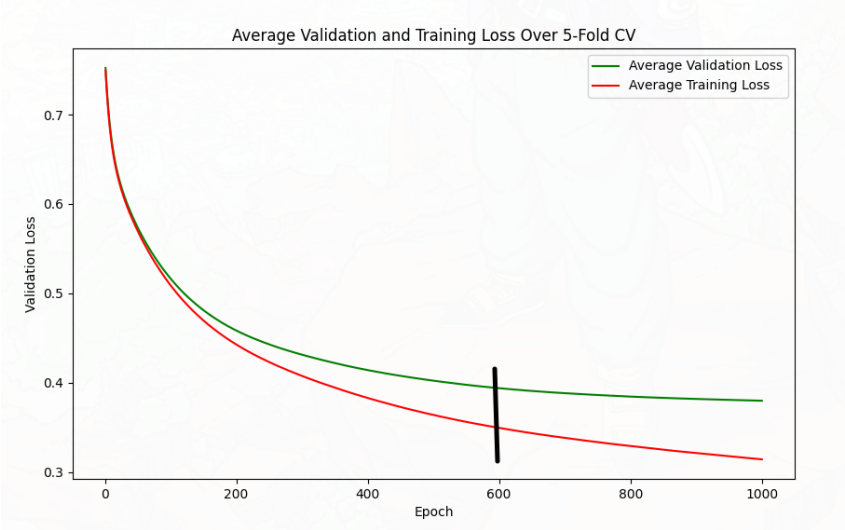

Σχήμα 9: Περίπου στα 600 epochs συμβαίνει το φαινόμενο.

3.6 (στ) Κριτήριο τερματισμού

Χρησιμοποιήθηκε *early stopping*:

- Παρακολουθώ το validation loss στο validation fold.
- Αν για 10 συνεχόμενες εποχές δεν βελτιώνεται κατά μια σταθερά(0.001) η CE, το σταματάω.

Με early stopping επιβεβαιώνεται και η παρατήρηση για τη σύγκλισή των epochs:

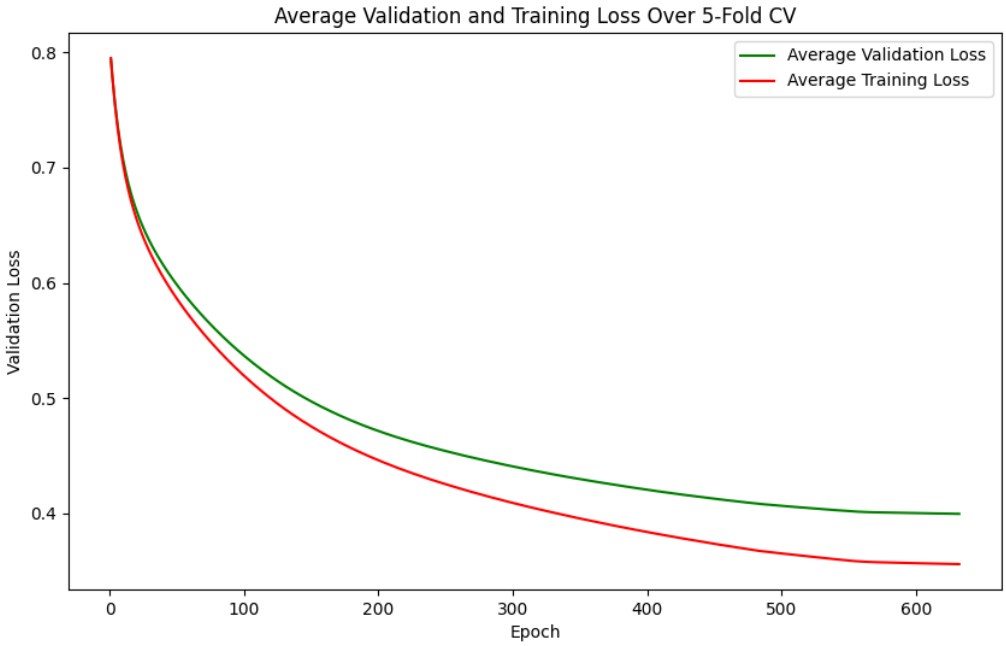

Σχήμα 10: Early stopping κοντά στα 600 epochs

Κώδικας:

```
    early_stopping = tf.keras.callbacks.EarlyStopping(
        monitor='val_loss',
        patience=10,
        min_delta=0.001,
        restore_best_weights=True
    )
```

4 Α3: Μεταβολές στον ρυθμό εκπαίδευσης και στη σταθερά ορμής

Έπειτα από επιλογή της καλύτερης τοπολογίας στο Α2, πειραματιστήκαμε με διαφορετικές τιμές η και m (learning rate και momentum). Ο πίνακας συνοψίζει τα αποτελέσματα μετά από 5-fold CV:

η	m	CE Loss	MSE	Accuracy
0.001	0.2	0.3862103223800659	0.11963917911052704	0.8366617918014526
0.001	0.6	0.37646722197532656	0.11473272740840912	0.8413118839263916
0.05	0.6	0.3590724289417267	0.1064189225435257	0.8599360227584839
0.1	0.6	0.36190045475959776	0.10914652198553085	0.8464411616325378

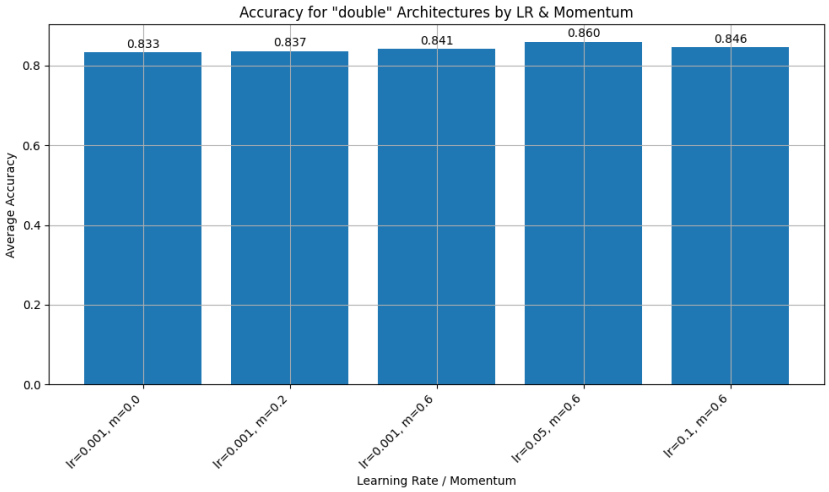

Σχήμα 11: Οι τιμές σε γράφημα

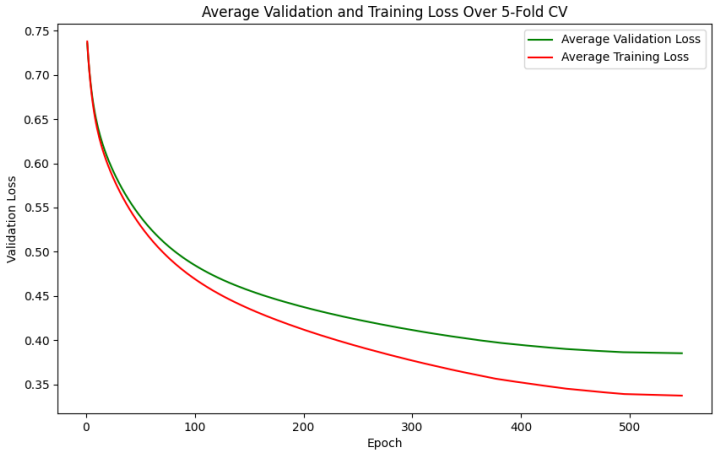

Σχήμα 12: m=0.2,η=0.001

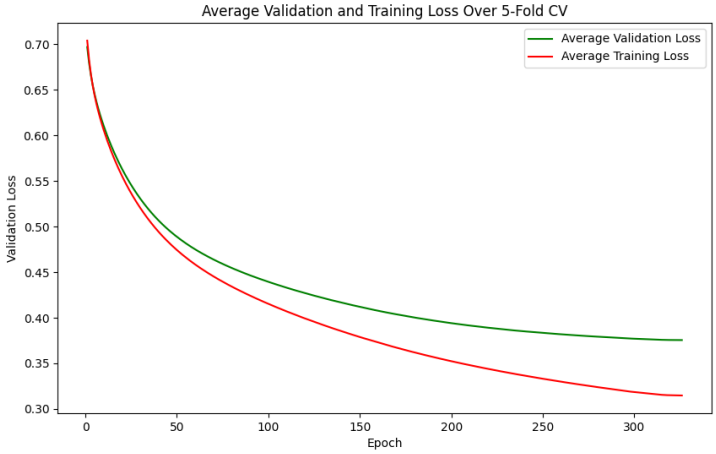

Σχήμα 13: m=0.6,η=0.001

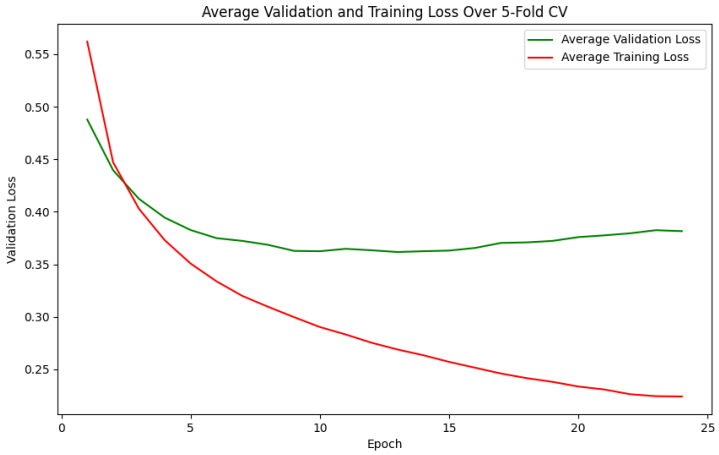

Σχήμα 14: m=0.6,η=0.05

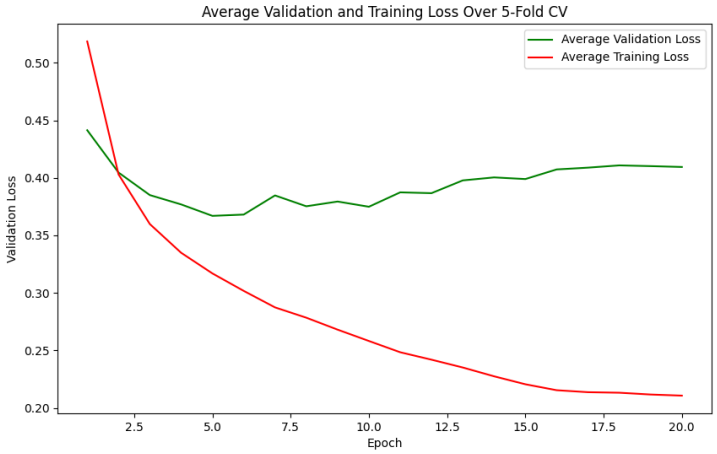

Σχήμα 15: m=0.6,η=0.01

Γιατί $m < 1$**:** Το momentum καθορίζει πόσο μέρος της ενημέρωσης των βαρών απο την προηγούμενη χρονική στιγμή συνυπολογίζεται με το τωρινό: $\Delta w_t = m\,\Delta w_{t-1} - \eta\,\nabla J(w_{t-1})$. Οπότε άν το m>1 μετά από πολλούς κύκλους ο όρος $m\,\Delta w_{t-1}$ θα γινόταν τεράστιος ,δυσκολεύοντας έτσι την σύγκλιση λόγω τεράστιων βημάτων και θα εγκλωβιζόταν σε τοπικά ελάχιστα.

Συμπεράσματα: Αν και για m=0.6,η=0.05 φαίνεται πως έχει τα καλύτερα αποτελέσματα, από τις γραφικές παραστάσεις φαίνεται πως η εκπαίδευση δεν είναι ομαλή και υπάρχει overfitting και σταδιακή αύξηση του loss. Γι αυτό επιλέγεται το m=0.6,η=0.001 που συγκλίνει στα μισά epochs από m=0/0.2 είναι ομαλό και έχει πολυ καλές μέσες τιμές.

Όπως φαίνεται από τις 2 τελευταίες γραφικές παραστάσεις όσο αυξάνεις το η τόσο πιο απότομες κινήσεις γίνονται με σκοπό την εύρεση του ελαχίστου, πράγμα που μπορεί να εγκλωβίζει την εκπαίδευση σε τοπικά ελάχιστα.Ο συνδυασμός κατάλληλου m ώστε μαζί με σχετικά μικρό η, δίνει το κατάλληλο άλμα(καθώς το m βασίζεται στις προηγούμενες θέσεις) και μειώνει τον αριθμό των epochs.

5 A4: Ομαλοποίηση (Regularization)

Για την αποφυγή υπερπροσαρμογής (overfitting), δοκιμάζω L1 και L2.Κάνω εκπαίδευση για 600 epochs.

$L1(r)$	**CE Loss**	**Accuracy**	**MSE**
0.0001	0.4038295090198517	0.8445785284042359	0.11286317259073257
0.001	0.5127061903476715	0.8585396051406861	0.10416208952665329
0.01	0.43445379137992857	0.8566726207733154	0.11263947784900666

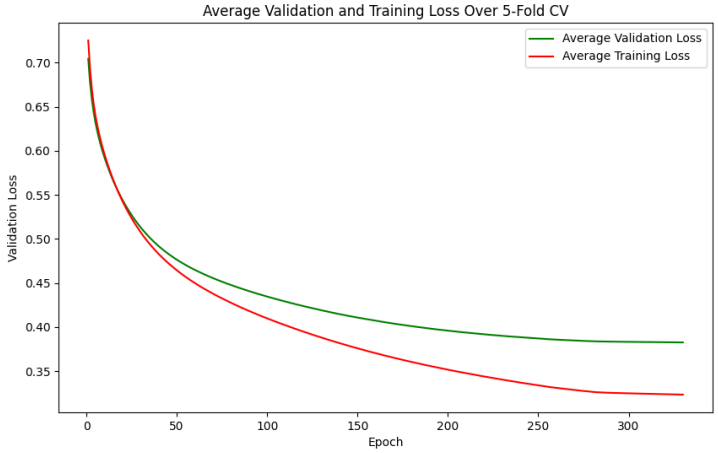

Σχήμα 16: r=0.0001

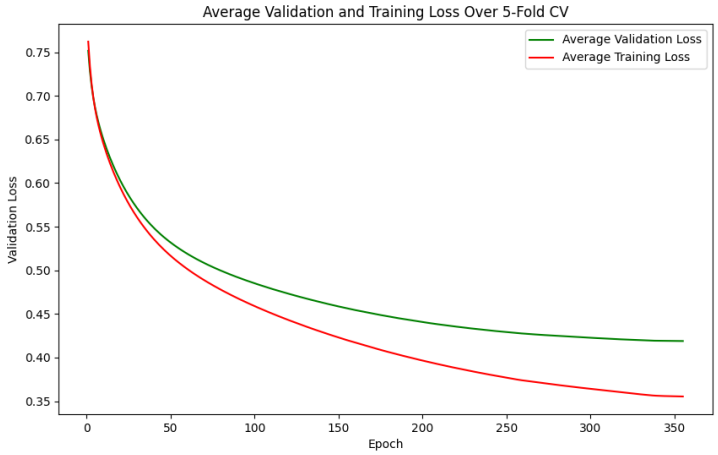

Σχήμα 17: r=0.001

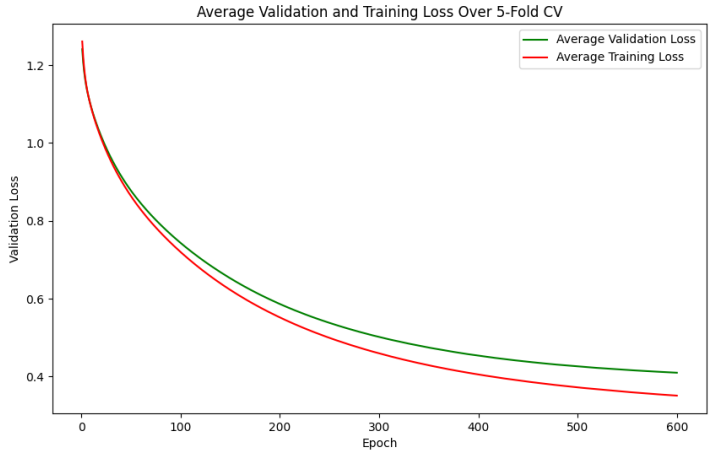

Σχήμα 18: r=0.01

$L2(r)$	**CE Loss**	**Accuracy**	**MSE**
0.0001	0.3834355592727661	0.8389960289001465	0.11614608764648438
0.001	0.4198959469795227	0.8348034858703614	0.11451027244329452
0.01	0.4104568600654602	0.856679129600525	0.10613797605037689

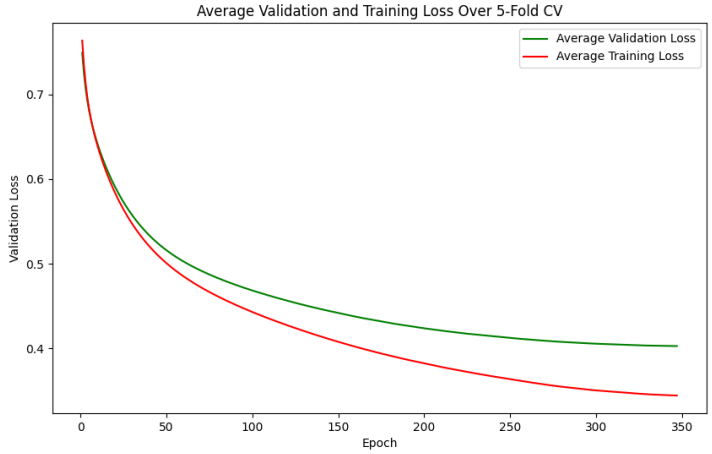

Σχήμα 19: r=0.0001

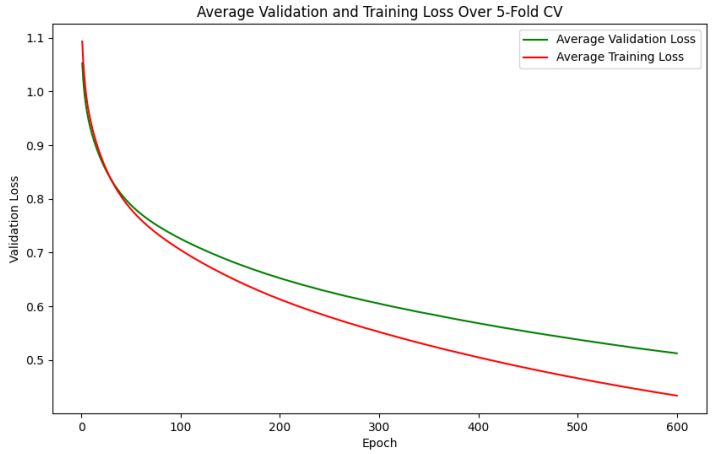

Σχήμα 20: r=0.001

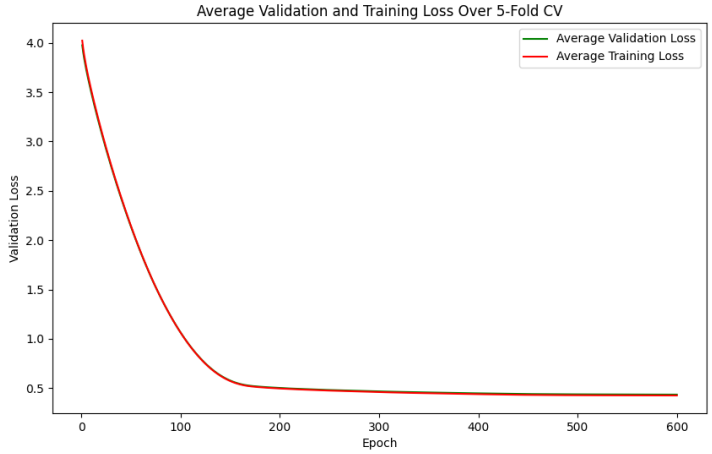

Σχήμα 21: r=0.01

Τρέχω τη καλύτερη τιμή του L1 για 1300 epochs

$L2(r)$	**CE Loss**	**Accuracy**	**MSE**
0.0001	0.4378849983215332	0.8636569499969482	0.09974857568740844

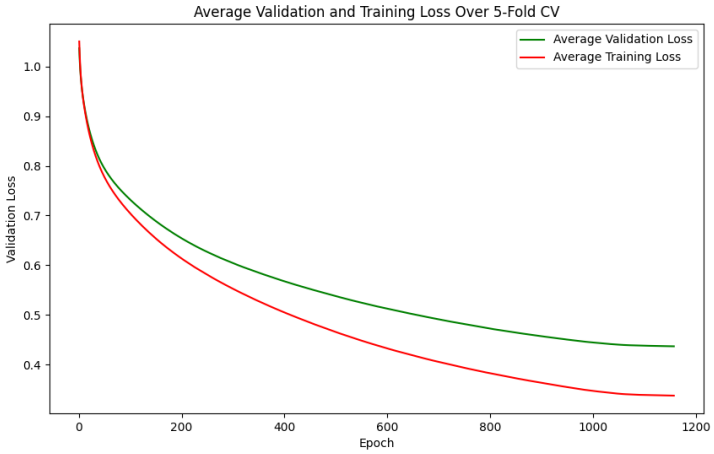

Σχήμα 22: Θέλει πάνω απο 1000 epochs για σύγκλιση

Συμπεράσματα: Τα καλύτερα accuracies τα δίνει το L1 και φαίνεται πως χρειάζεται παραπάνω από 600 epochs όπως επιλέχθηκαν πριν για να συγκλίνει ιδιαίτερα για το r=0.001 που δίνει την μεγαλύτερη ακρίβεια.Το L2 ωστόσο δεν χάνει υπερβολικά στην ακρίβεια σε σχέση με το L1 και συγκλίνει πιο γρήγορα. Τέλος, το L2 για να έχει την καλύτερη απόδοση πρέπει έχει μεγάλο r σε αντίθεση με το L1 που χάνει ακρίβεια.
Τα αποτελέσματα βγάζουν νόημά και για τις 2 περιπτώσεις.Το L1 εξαφανίζει τα άχρηστα χαρακτηριστικά μηδενίζοντας τα βάρη τους, οπότε σε 1 μικρό Dataset όπως αυτό βγάζει καλύτερα αποτελέσματα.Το L2 ρυθμίζει πιο ομαλά τα βάρη και ίσως σε περισσότερα δεδομένα θα ήταν καλύτερος εκτιμητής.Οπότε εν τέλει έχει σημασία η σχεδιαστική προτίμηση και για την απλότητα του παραδείγματος επιλέγω το L1.

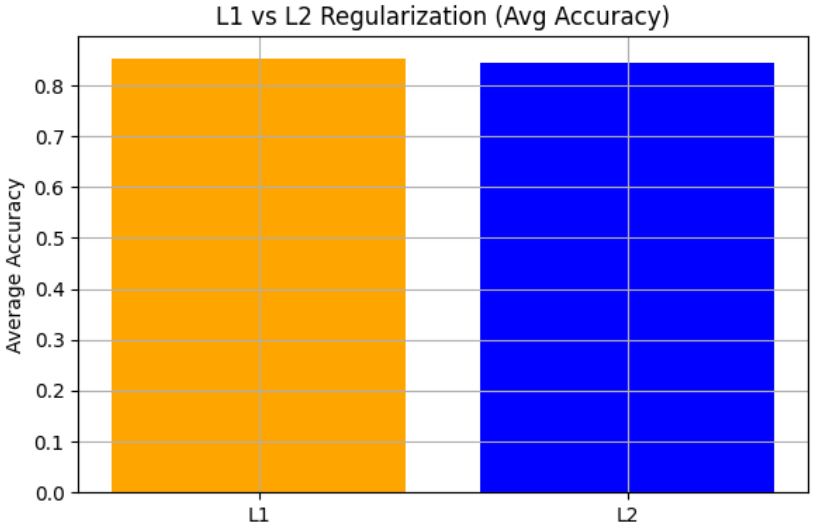

Σχήμα 23: Η σύγκριση τους σε γράφημα

6 A5: Βαθύ Νευρωνικό Δίκτυο

Δοκιμάστηκε η επέκταση σε δύο και τρία κρυφά επίπεδα. Έτρεξα όλους τους συνδυασμούς για τιμές 32,64,128,256 για να βρώ την καλύτερη τοπολογία καθώς και δοκίμασα τις καλύτερες L1 και L2 για να δω πως επηρεάζουν την εκπαίδευση με πολλά επίπεδα.

6.1 Δοκιμές με L1

6.1.1 Ακρίβεια-Αρχιτεκτονική-Αριθμός Νευρώνων

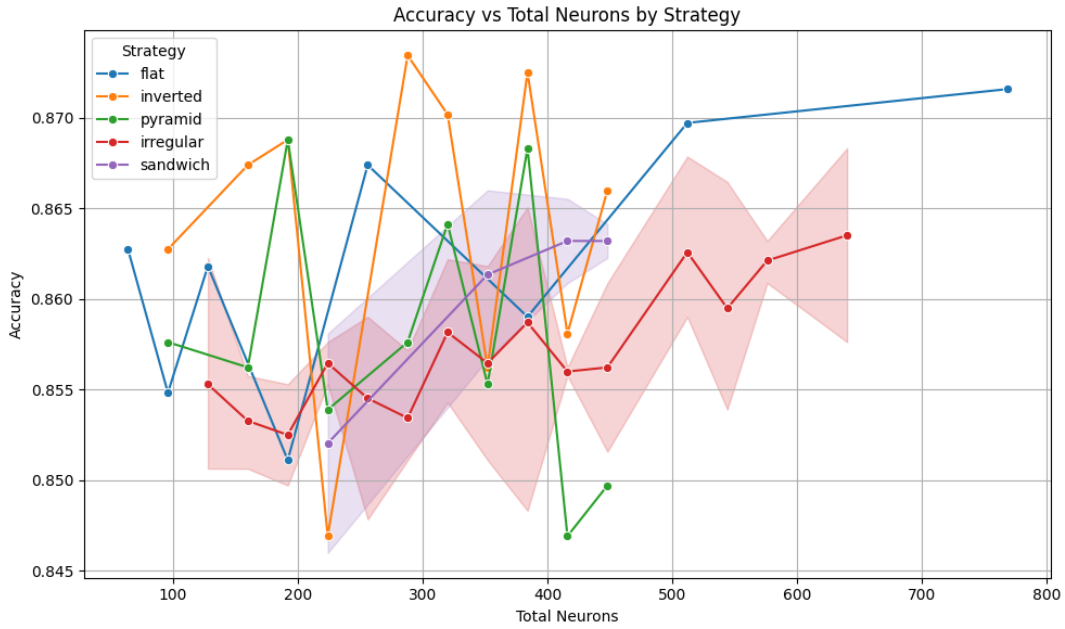

Οι καλύτερες αρχιτεκτονικές είναι οι inverted,pyramid και flat.Οι δύο πρώτες δίνουν καλύτερα αποτελέσματα μικρό/μεσαίο αριθμό νευρώνων ενώ η flat έχει έναν ποιο σταθερό ρυθμό που για κάθε τύπου αριθμό έχει καλές τιμές.Η flat και η inverted επιτυγχάνουν accuracy μεγαλύτερο του 0,87.
Τέλος όπως φαίνεται και στον πίνακα οι 5 καλύτερες στρατηγικές έχουν πολύ καλές μέσες τιμές, δηλαδή αυξάνουν την αποδοτικότητα γενικά της εκπαίδευσης σε σχέση με 1 επίπεδο, ενώ οι χειρότερες δεν δίνουν κάποια βελτίωση.

Πίνακας 1: Best Configurations Based on Accuracy

Architecture	Strategy	Num Layers	Run Epochs	Accuracy	MSE	Loss
32,256	inverted	2	1048	0.873429	0.095236	0.396349
128,256	inverted	2	1043	0.872495	0.095589	0.397617
256,256,256	flat	3	1102	0.871566	0.097962	0.448519
64,256	inverted	2	1057	0.870171	0.095272	0.395603
256,256	flat	2	1049	0.869702	0.096572	0.399879

Πίνακας 2: Worst Configurations Based on Accuracy

Architecture	Strategy	Num Layers	Run Epochs	Accuracy	MSE	Loss
256,64,64	irregular	3	1078	0.848305	0.111066	0.616754
128,64,64	irregular	3	1100	0.847828	0.112792	0.623555
32,64,128	inverted	3	1100	0.846906	0.107798	0.559700
256,128,32	pyramid	3	1100	0.846904	0.108825	0.587678
32,128,64	sandwich	3	1100	0.845978	0.109213	0.585184

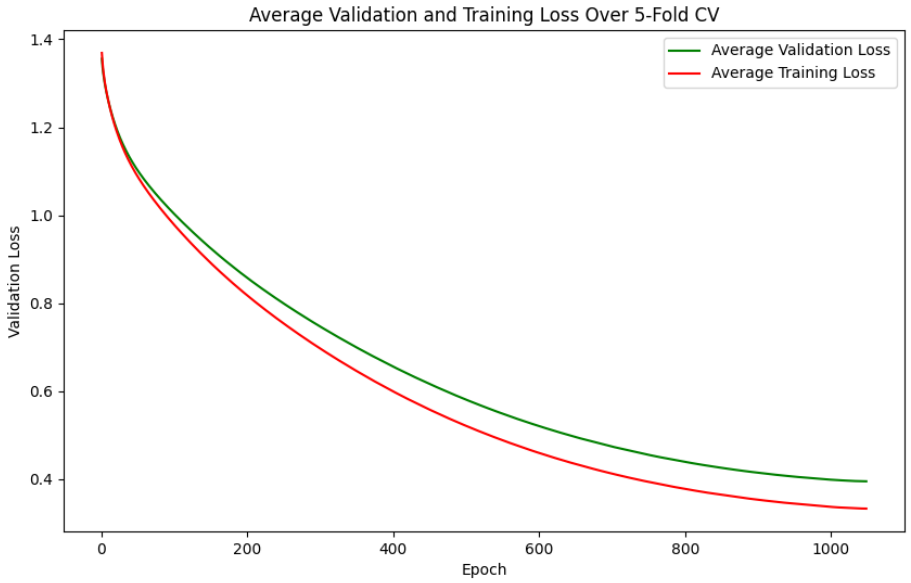

Σχήμα 24: Η [32,256] έχει το πιο ομαλό plot και παρουσιάζει το λιγότερο overfitting όπως φαίνεται.

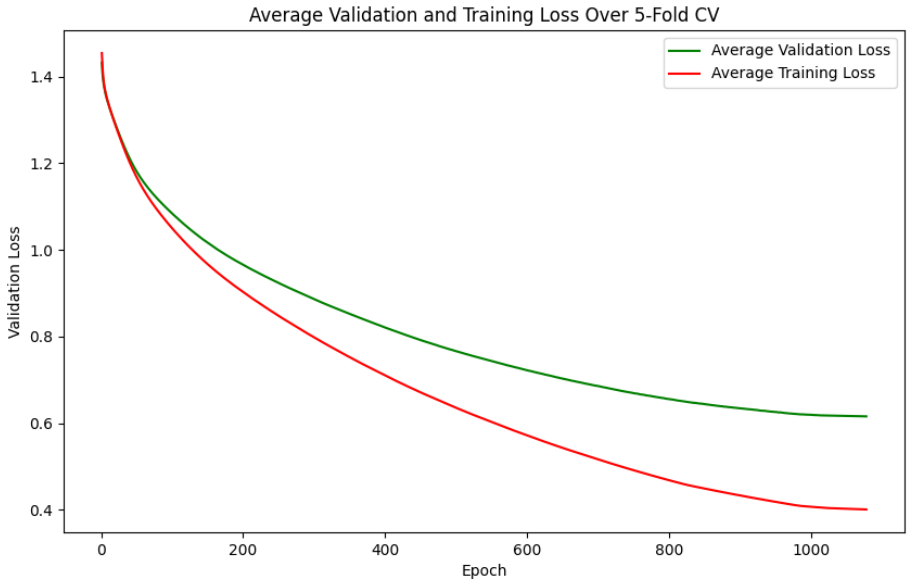

Σχήμα 25: Η [256,64,64] έχει την χειρότερη απόδοση και η απόσταση μεταξύ των losses αυξάνεται με μεγάλο ρυθμό.

Σημείωση:Οι υπόλοιπες φωτογραφίες των loss plots δεν συμπεριλαμβάνονται στην αναφορά για εξοικονόμηση χώρου(είναι 80 συνολικά), αλλά υπάρχουν στο github και οι καλύτερες αρχιτεκτονικές είναι το ίδιο ομαλές με τη [32,256] , ενώ οι χειρότερες παρουσιάζουν το ίδιο πρόβλημα με τη [32,128,64].

6.1.2 Αποδοτικότητα του αριθμού των κρυφών επιπέδων

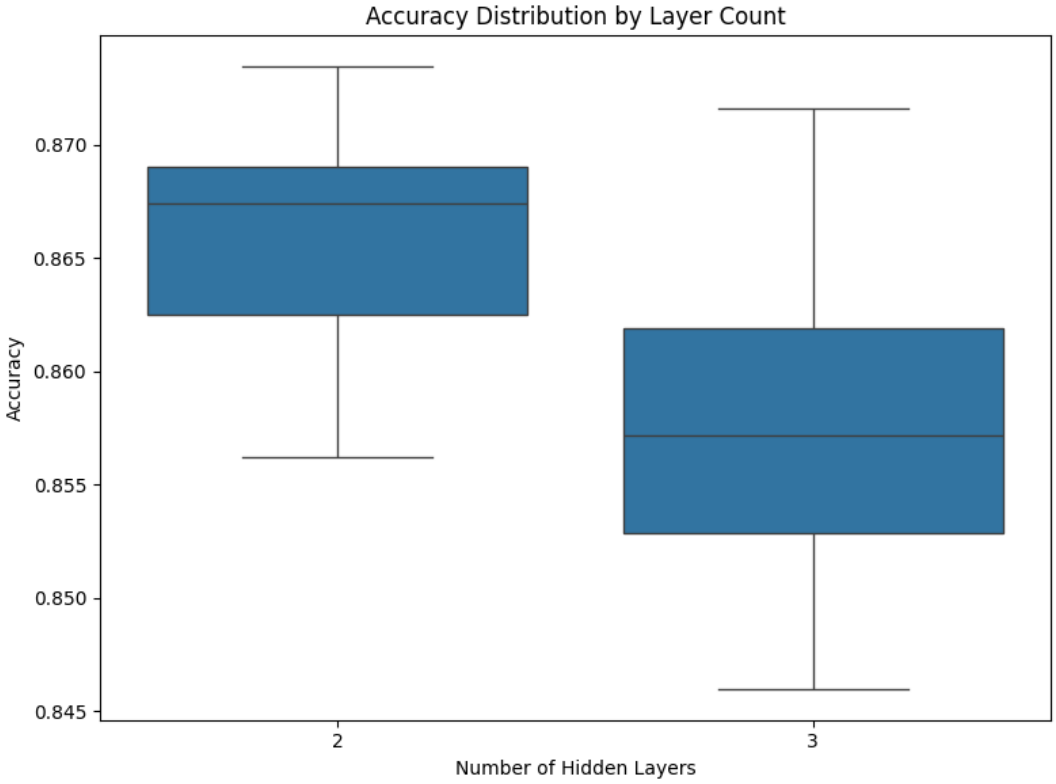

Για L1 καλύτερη απόδοση έχει ο μικρότερος αριθμός των επιπέδων(2), το οποίο είναι λογικό καθώς σε ένα πιο απλό μοντέλο ένα απλό tuning των weights είναι πιο αποδοτικό για την καταπολέμηση του overfitting.Σε ένα πιο πολύπλοκο δίκτυο όμως χρειάζεσαι μια πιο προσεκτική προσέγγιση(L2).

6.1.3 Αριθμός epochs για σύγκλιση

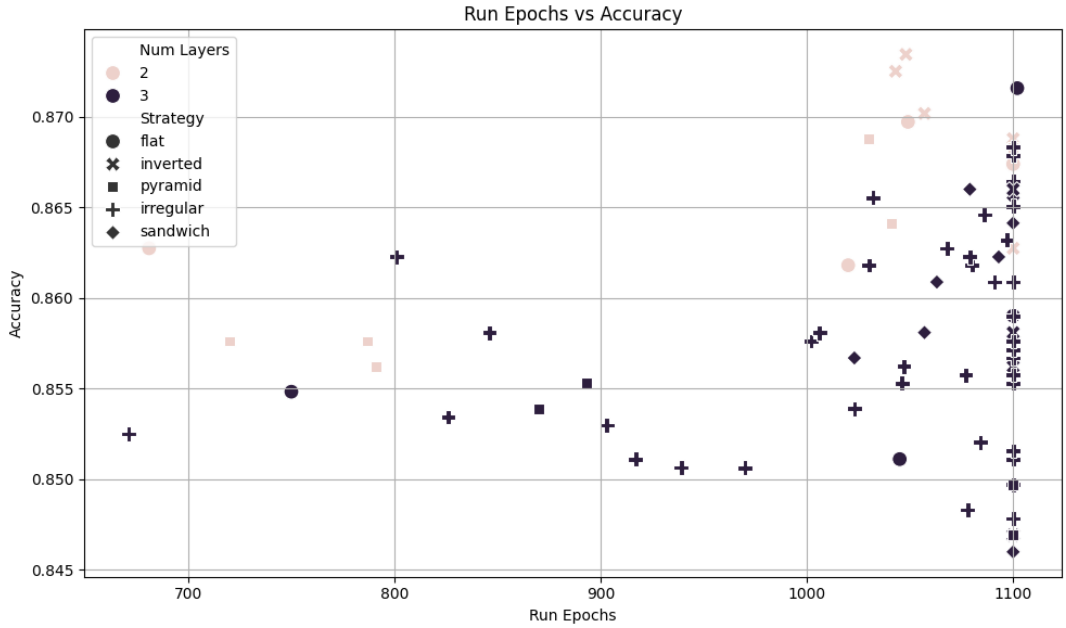

Χρειάζεται μεγαλύτερος αριθμός epochs για να συγκλίνει εκπαίδευση(400-500 παραπάνω) σχεδόν για όλους τους συνδυασμούς, το οποίο είναι λογικό καθώς ο μεγαλύτερος αριθμός νευρώνων + επιπέδων + αργή συνάρτηση Regularization(όπως διαπιστώθηκε σε προηγούμενο ερώτημα) καθιστά πιο αργή(αλλά πιο ακριβή την εκπαίδευση).

6.2 Δοκιμές με L2

6.2.1 Ακρίβεια-Αρχιτεκτονική-Αριθμός Νευρώνων

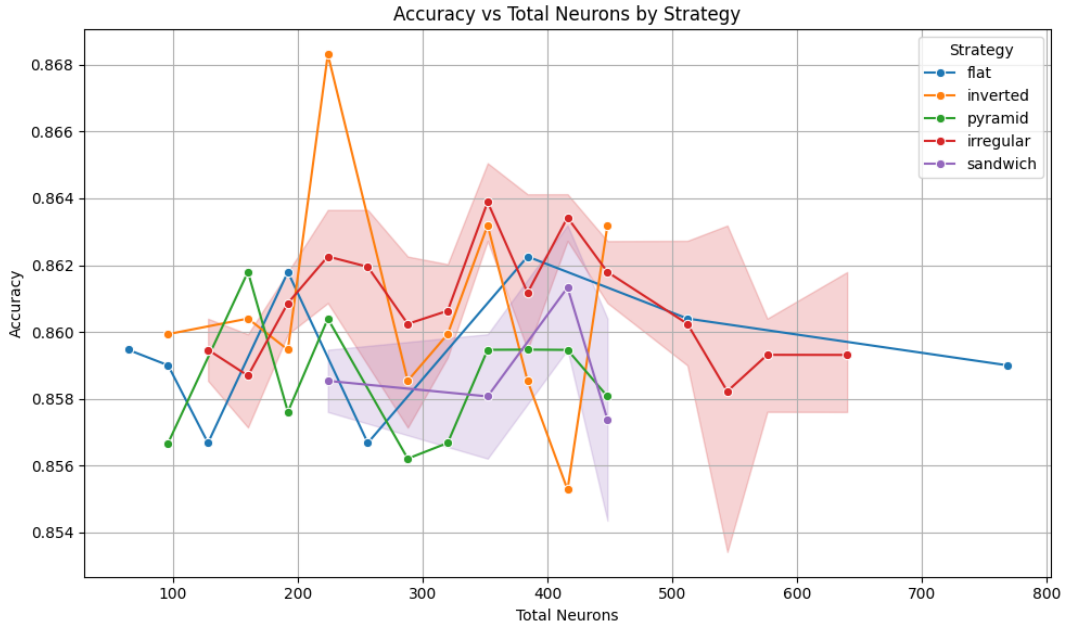

Πίνακας 3: Top 5 Best Architectures

Architecture	Strategy	Num Layers	Run Epochs	Accuracy	MSE	Loss
32,64,128	inverted	3	721	0.868307	0.100675	0.446260
256,32,64	irregular	3	652	0.865052	0.099490	0.432573
256,32,128	irregular	3	670	0.864124	0.102504	0.438658
64,64,256	irregular	3	730	0.864122	0.100610	0.450053
128,32,64	irregular	3	665	0.863654	0.101460	0.433669

Παρόμοια αποτελέσματα με πριν με τη μόνη διαφορά η irregular αρχιτεκτονική(όχι κάποιο μοτίβο) έχει πάρει την θέση της πυραμίδας.Πάλι η inverted δίνει την καλύτερη μετρική η οποία είναι πάλι στην κλίμακα του 0,87.Οι καλύτερες αποδόσεις για όλες τις αρχιτεκτονικές είναι για μικρό/μεσαίο αριθμό νευρώνων.

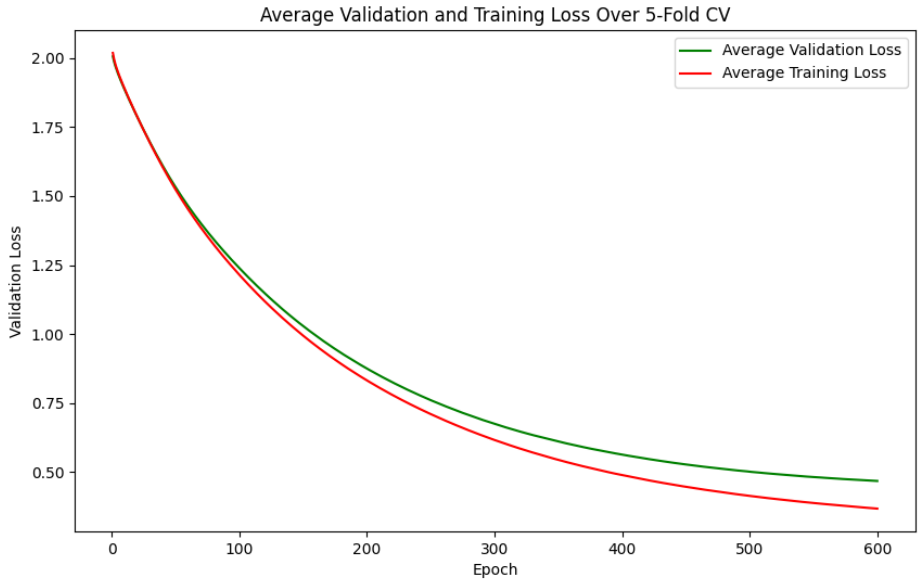

Σχήμα 26: Η σύγκλιση είναι πιο γρήγορη σε σχέση με την L1 ,ίδιο ομαλή με μικρή διαφορά στην ακρίβεια

Σημείωση: Οι χειρότερες περιπτώσεις δεν περιλαμβάνονται αλλά υπάρχουν και πάλι στο github, γιατί βγάζω το ίδιο συμπέρασμα με πριν.

6.2.2 Αποδοτικότητα του αριθμού των κρυφών επιπέδων

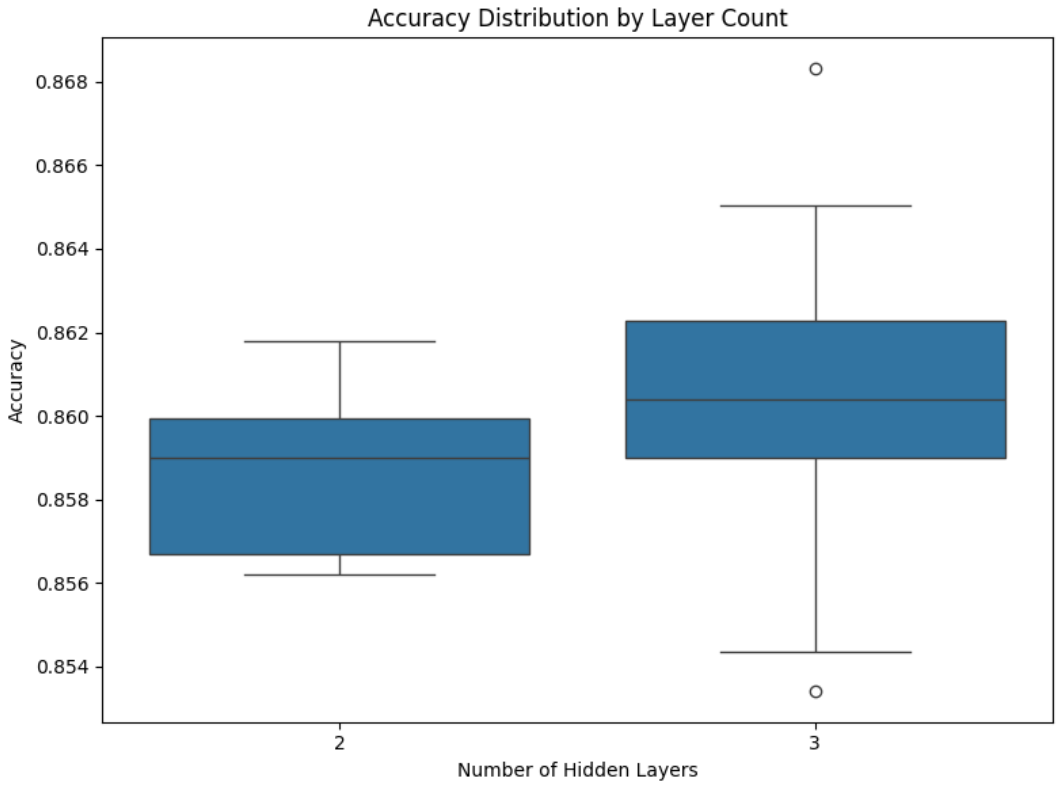

Όπως παρατηρήθηκε και πριν η L2 είναι καλύτερη για μεγαλύτερο αριθμό κρυφών επιπέδων.

6.2.3 Αριθμός epochs για σύγκλιση

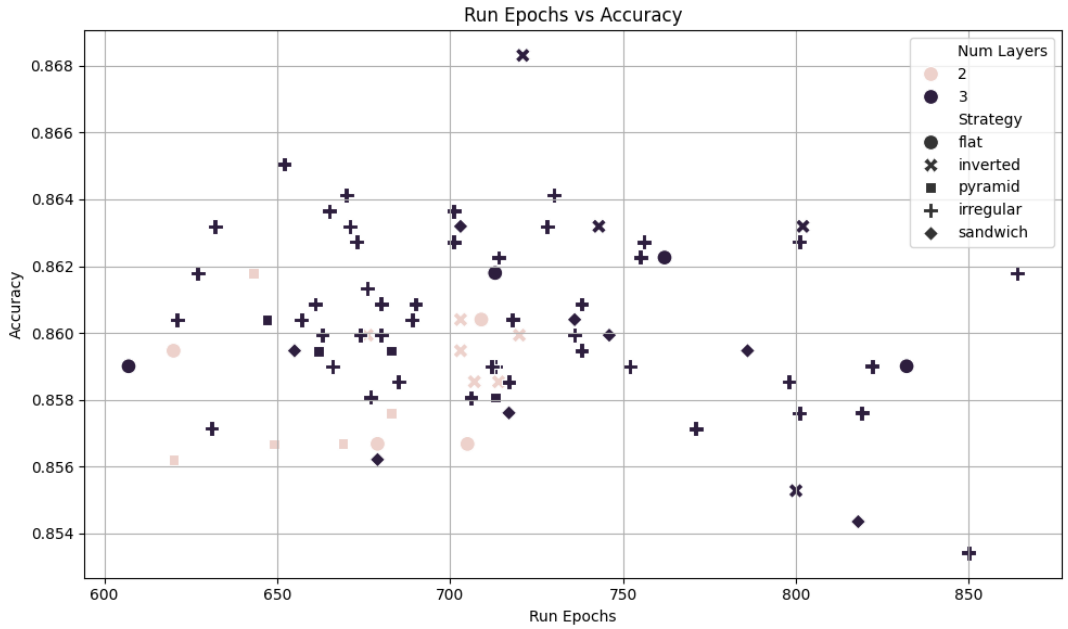

Οι περισσότερες προσπάθειες συγκλίνουν στα 650-750 epochs, περισσότερα από 1 μόνο επίπεδο αλλά καλύτερο ποσοστό ακρίβειας/epochs σύγκλισής από την L1.

6.3 Συμπέρασμα πειραμάτων πολλών επιπέδων

Γενικά τα περισσότερα επίπεδα δίνουν μεγαλύτερη ακρίβεια από το 1 αλλά χρειάζονται περισσότερο χρόνο για να συγκλίνουν.Η αρχιτεκτονική εξαρτάται όπως είδαμε από το Regularization αλλά και στις 2 περιπτώσεις τα καλύτερα αποτελέσματα τα έδωσε η inverted αρχιτεκτονική για σχετικά μικρό αριθμό νευρώνων:

- 32+64+128=224 για την L2
- 32+256=288 για την L1

Ο αριθμός των κρυφών επιπέδων εξαρτάται και πάλι απο το αν θα χρησιμοποιήσεις L1,L2 αλλά και οι 2 περιπτώσεις δίνουν πολύ καλές μέσες μετρικές.
Τέλος, οι πάρα πολλοί ή λίγοι νευρώνες και η λάθος αρχιτεκτονική ενώ μπορεί να δίνουν καλύτερα αποτελέσματα από 1 κρυφό επίπεδο δεν αξιοποιούν την πλήρη δύναμη των κρυφών επιπέδων, λόγω των εξής προβλημάτων:

- Uderfitting ή overfitting σε συνδυασμό με λάθος αρχιτεκτονική, κάθε επίπεδο δέν έχει το σωστό αριθμό νευρώνων για να μάθει τον τύπο των χαρακτηριστικών του και δεν υπάρχει σωστή διασύνδεση μεταξύ επιπέδων, δηλάδή σωστός τρόπος και όγκος μεταφοράς πληροφορίας π.χ.(L1):

Architecture	Strategy	Num Layers	Run Epochs	Accuracy	MSE	Loss
256,128,32	pyramid	3	1100	0.846904	0.108825	0.587678
256,64,64	irregular	3	1078	0.848305	0.111066	0.616754

- Η αρχικτεκτονική των δικτύων επηρεάζει τον τρόπο με τον όποιο συγκλίνει ο SGD π.χ. η sandwich αρχιτεκτονική και στις 2 περιπτώσεις είναι πολύ κακή αρχιτεκτονική για πολλές τιμές.

7 Συνολικά Συμπεράσματα

Συνοψίζοντας:

- Για pre-processing η καλύτερη μέθοδος είναι η z-score
- Οι καλύτερες παράμετροί είναι οι : η=0.001,m=0.6,L1(r)=0.001
- Για περισσότερα του ενός κρυφού επιπέδου σε συνδυασμό με την Regularization function που χρησιμοποιείται, αυξάνεται η ακρίβεια, η εκπαίδευση παραμένει ομαλή αλλά χρειάζεται περισσότερος χρόνος για την ολοκλήρωση της εκπαίδευσης.

8 Πράρτημα με πληροφορίες για τον κώδικα

Το βασικό αρχείο είναι το alzheimers_prediction.py.Χρησιμοποιείται parser για να μπορεί ο χρήστης δυναμικά να βάζει επιλογές για την εκπαίδευση.Πέρα απο το βασικό αρχείο υπάρχουν τα results.py και deep_results.py για να βγάλω διάφορες μετρικές για το 1 και τα πολλά layers αντίστοιχα.
Τέλος υπάρχει το run.py/deep_run.py που τρέχει όλες τις τιμές που ζητούνται και ο φάκελος screenshots που για τα plots.

Οι επιλογές με τις οποίες μπορεί να τρεχτεί το alzheimers_prediction.py:

`--pre_processing` **Type:** `str`, **Default:** `"z-score"`
Επιλογή της pre-processing μεθόδου, default:z-score.

`--optimizer` **Type:** `str`, **Default:** `"adam"`
Επιλογή Optimizer, default:adam

`--lr` **Type:** `float`, **Default:** 0.001
Επιλογή του η, default:0.001

`--momentum` **Type:** `float`, **Default:** 0.0
Επιλογή του m για τον SGD, default:0

`--epochs` **Type:** `int`, **Default:** 50
Τα epochs εκπαίδευσης.

`--num_of_layers` **Type:** `str`, **Default:** `"two thirds"`
Ο αριθμός των layers. Επιλογές: `I/2`, `2*I/3`, `I`, `2*I`.

`--loss_func` **Type:** `str`, **Default:** `"cross entropy"`
Το loss function. Επιλογές: cross entropy, MSE.

`--hid_layer_func` **Type:** `str`, **Default:** `"Relu"`
Συνάρτηση ενεργοποίησης για τα κρυφά επίπεδα. Επιλογές: Relu, Tanh, Silu.

`--r` **Type:** `float`, **Default:** None
Το r, default:0.

`--all_weights` **Type:** `bool`, **Default:** False
Τρέξιμο για όλες τις τιμές των βαρών χωρίς early stop.

`--test_lr_moment` **Type:** `bool`, **Default:** False
Παρόμοια για τα ζευγάρια η,m.

`--test_reg` **Type:** `bool`, **Default:** False
Παρόμοια για τα r.

`--normal` **Type:** `bool`, **Default:** True
Κανονική εκπαίδευση με βάση τις παραμέτρους.

`--compare_losses` **Type:** `bool`, **Default:** False
Δείχνει τα loss plots ξεχωριστά για κάθε fold και όχι το μέσο όρο τους.

`--more_layers` **Type:** `bool`, **Default:** False
Χρήση περισσότεων layers.

`--use_l2` **Type:** `bool`, **Default:** False
L2 regularization.

`--use_l1` **Type:** `bool`, **Default:** False
L1 regularization.

`--hidden_layers` **Type:** `str`, **Default:** `""`
Η αρχιτεκτονική του βαθύ δικτύου π.χ.: ”32,256”.

Παράδειγμα χρήσης:

```
python3 alzheimers_prediction.py --optimizer SGD --epochs 600 --num_of_layers double \
--lr 0.001 --momentum 0.6 --use_l1 True --r 0.001
```

Σημείωση:Τα αποτελέσματα αποθηκεύνται στην mongoDB, προσοχή όταν τρέχετε το py αρχείο. Το github θα γίνει προσβάσιμο ακριβώς μετά την λήξη της προθεσμίας για λόγους αντιγραφής.